

EDA Técnico — Pipeline de Preprocesamiento y Diagnóstico (PPD)

Proyecto Integrador — Data Science III: NLP & Deep Learning
Coderhouse — Entrega 2 (Módulo 2)

Dataset: AG News | Documentos analizados (train): 8000 | Clases: 4

1. Resumen de pasos de preprocesamiento aplicados


Se implementó la función **preprocess_text(text)**, que integra las siguientes etapas, aplicadas en orden sobre cada documento del corpus de entrenamiento:

- **Decodificación de entidades HTML:** Se detectó que ~4.5% de los documentos de AG News contienen entidades HTML sin decodificar (ej. `<FONT>`, producto de tags de cotización bursátil incrustados en las noticias originales). Se decodifican con `html.unescape()` antes de cualquier otra limpieza.
- **Limpieza con Regex:** Remoción de URLs (`http/https/www`), tags HTML remanentes y todo carácter no alfabético (dígitos, signos de puntuación, símbolos).
- **Normalización:** Conversión a minúsculas y colapso de espacios múltiples/saltos de línea a un único espacio.
- **Lematización con spaCy:** Se usa el modelo `en_core_web_sm` para reducir cada token a su lema (ej. `'appointed' → 'appoint'`, `'companies' → 'company'`), reduciendo la dispersión del vocabulario.

Nota sobre el corpus: este es el primer checkpoint donde se trabaja sobre el corpus real que se usará en el resto del programa (Módulos 3, 4 y Proyecto Final): AG News, dataset provisto por la cátedra, con 8.000 documentos de entrenamiento distribuidos en 4 clases perfectamente balanceadas (2.000 documentos cada una: Business, Sci_Tech, Sports, World).

2. Distribución de longitud de tokens

Tras el preprocesamiento, la longitud de los documentos (en tokens) tiene una mediana de **37 tokens**, con un mínimo de 7 y un máximo de 144. El **percentil 95 es de 53 tokens**, valor que se toma como referencia de `max_len` para el padding/truncation en los modelos de los próximos módulos: cubre al 95% del corpus sin generar secuencias innecesariamente largas.



Al ser AG News un dataset de titulares/resúmenes cortos, la distribución está concentrada en un rango relativamente angosto (la mayoría de los documentos entre 20 y 55 tokens), sin una cola larga extrema, lo cual simplifica la elección de `max_len` para el módulo de fine-tuning.

3. Bi-gramas y tri-gramas más frecuentes

Se extrajeron los N-gramas más frecuentes del corpus lematizado con CountVectorizer (scikit-learn). A continuación, el top 20 de bi-gramas y tri-gramas:

Top 20 bi-gramas

Bi-grama	Frecuencia
of the	1410
in the	1383
for the	610
ap ap	529
to the	485
on the	462
new york	419
at the	394
have be	333
the world	307
the first	297
with the	295
on wednesday	272
on tuesday	267
and the	266
on monday	265
say on	249
on thursday	245
to be	242
as the	242

Top 20 tri-gramas

Tri-grama	Frecuencia
new york reuters	151
the united states	149
one of the	107
ap ap the	85
for the first	71
the first time	71
quote profile research	69

Tri-grama	Frecuencia
kill at least	57
be expect to	56
the world large	55
of the year	55
in the first	53
the new york	52
say on tuesday	51
of the season	49
the end of	47
the european union	47
of the world	47
say on wednesday	45
round of the	44


Interpretación: la mayoría de los bi-gramas top están dominados por combinaciones de preposiciones/artículos ('of the', 'in the', 'for the'), esperable en cualquier corpus en inglés y sin valor semántico distintivo por sí solas. Entre los patrones con más carga informativa aparecen '*new york*' (dateline geográfico típico de cables de noticias) y '*ap ap*' (duplicación de la marca de la agencia Associated Press en el texto fuente). En los tri-gramas se destacan '*new york reuters*' y '*the united states*', ambos datelines/entidades geográficas recurrentes en noticias de agencia, junto con secuencias como '*quote profile research*', residuo de bloques de cotización bursátil embebidos en el texto original de algunas noticias de Business/Sci_Tech. No se observan tags HTML ni entidades sin decodificar entre los N-gramas más frecuentes, lo cual confirma que la etapa de limpieza fue efectiva.

4. Palabras más frecuentes y stop-words

De las 50 palabras más frecuentes del corpus lematizado, **35 de 50 (70%) son stop-words** estándar del inglés (según el listado de scikit-learn). Es un resultado esperado: en cualquier corpus en lenguaje natural, las palabras funcionales (artículos, preposiciones, conjunciones) dominan el ranking de frecuencia absoluta. Esto valida la decisión de **no** remover stop-words en esta etapa de EDA (para poder diagnosticarlas), reservando su filtrado para la etapa de vectorización (Módulo 3), donde sí afectan negativamente a métodos como TF-IDF si no se controlan.

5. Distribución de clases

El corpus de entrenamiento de AG News está **perfectamente balanceado**: 2.000 documentos por cada una de las 4 clases (Business, Sci_Tech, Sports, World). Esto simplifica el entrenamiento de los módulos siguientes: no va a ser necesario aplicar estrategias de balanceo (undersampling, oversampling, class weights) y accuracy va a ser una métrica confiable, sin necesidad de recurrir obligatoriamente a F1 macro/weighted para compensar desbalanceo (aunque igualmente se recomienda reportarlas como buena práctica).



6. Conclusión sobre la preparación del dato para el modelo final

El corpus AG News, tras el pipeline de preprocesamiento aplicado, queda en condiciones adecuadas para el modelado: el principal desafío detectado fue la presencia de entidades HTML sin decodificar en aproximadamente el 4.5% de los documentos, originadas en bloques de cotización bursátil embebidos en las noticias de fuente. Sin una decodificación explícita previa a la remoción de tags, ese ruido se filtraba directamente al vocabulario final, contaminando los N-gramas con tokens sin valor semántico ('lt', 'gt', 'href'). Una vez corregido, los N-gramas más frecuentes reflejan patrones lingüísticos genuinos del corpus (preposiciones comunes, datelines geográficos y menciones a agencias de noticias), sin residuos de marcado. En cuanto a la distribución de clases, el corpus está perfectamente balanceado (2.000 documentos por clase), lo que evita la necesidad de técnicas de re-balanceo en los módulos de modelado posteriores y permite usar accuracy como métrica principal sin perder representatividad. Respecto a la longitud, los documentos son mayormente cortos (mediana de 37 tokens, percentil 95 en 53), coherente con el formato de titular/resumen de AG News; este valor se toma como max_len de referencia para el truncation/padding en el fine-tuning del Módulo 4, minimizando el cómputo desperdiciado en padding sin descartar información relevante de la cola larga del corpus.